



گزارش کار پروژه دوره آمار و ریاضیات تحلیلگر داده آکادمی همراه

صفحه عنوان

عنوان پروژه: تحلیل داده‌های تبلیغاتی با پایتون و روش‌های آماری، ماتریسی و بیزی
نام دانش پذیر: محمدمهدی حیدری
تاریخ: 1405/03/06.

گزارش پروژه تحلیل داده‌های تبلیغاتی

مقدمه

در این پروژه، یک دیتاست واقعی مربوط به تبلیغات بررسی شده است که شامل هزینه‌های تبلیغاتی در سه رسانه‌ی **تلویزیون (TV)**، **رادیو (Radio)** و **روزنامه (Newspaper)** به همراه میزان **فروش (Sales)** است. هدف اصلی پروژه، تحلیل ساختار داده‌ها، بررسی روابط میان متغیرها، استفاده از ابزارهای جبر خطی برای تحلیل ماتریسی و کاهش ابعاد، برازش مدل رگرسیون خطی با روش حداقل مربعات، و در نهایت انجام یک استدلال بیزی برای برآورد احتمال رخداد «فروش بالا» است.

این گزارش به صورت مرحله به مرحله تنظیم شده و در هر بخش، علاوه بر توضیح مفهومی، کدهای مربوطه نیز ارائه شده‌اند. برای هر قسمت، محل مناسب جهت درج خروجی اجرای کد نیز در نظر گرفته شده است تا گزارش نهایی از نظر علمی و ظاهری ساختاریافته و حرفه‌ای باشد.

کشف و پردازش داده‌ها

هدف این بخش

در گام نخست، ساختار کلی داده‌ها بررسی می‌شود. سپس با استفاده از شاخص‌های آماری توصیفی مانند میانگین، میانه، واریانس و انحراف معیار، وضعیت هر یک از متغیرها تحلیل می‌شود. همچنین برای شناخت بهتر توزیع داده‌ها و شناسایی نقاط پرت، از نمودارهایی مانند هیستوگرام و نمودار جعبه‌ای استفاده می‌شود.

بارگذاری کتابخانه‌ها و خواندن داده

```
[4]: import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
```

```
[3]: data = pd.read_csv('advertising_Dataset.csv')
data
```

بررسی اولیه ساختار داده

در این مرحله، تعداد سطرها و ستون‌ها، نوع داده‌های هر متغیر و وجود یا عدم وجود داده‌های گمشده بررسی می‌شود. این بررسی پایه‌ای برای اطمینان از صحت داده‌ها پیش از ورود به تحلیل‌های پیشرفته‌تر است.

```
[11]: data.isnull().sum()
```

```
[11]: TV          0
Radio         0
Newspaper     0
Sales         0
dtype: int64
```

4-1. آمار توصیفی

در این بخش، شاخص‌های اصلی آماری برای متغیرهای TV، Radio، Newspaper و Sales محاسبه می‌شوند. میانگین و میانه برای بررسی مرکز داده‌ها، واریانس و انحراف معیار برای سنجش پراکندگی، و کمینه و بیشینه برای تعیین دامنه تغییرات مورد استفاده قرار می‌گیرند.

```
[12]: data.describe()
```





```
[12]:
```

	TV	Radio	Newspaper	Sales
count	200.000000	200.000000	200.000000	200.000000
mean	147.042500	23.264000	30.554000	14.022500
std	85.854236	14.846809	21.778621	5.217457
min	0.700000	0.000000	0.300000	1.600000
25%	74.375000	9.975000	12.750000	10.375000
50%	149.750000	22.900000	25.750000	12.900000
75%	218.825000	36.525000	45.100000	17.400000
max	296.400000	49.600000	114.000000	27.000000

Activate Windows
Go to Settings to activate Windows.


رسم هیستوگرام

هیستوگرام‌ها شکل توزیع هر متغیر را نشان می‌دهند و برای بررسی تقارن، چولگی، تراکم داده‌ها و گستره مقادیر مفید هستند.



رسم نمودار جعبه‌ای

نمودار جعبه‌ای برای نمایش میانه، چارک‌ها، دامنه بین چارکی و شناسایی نقاط پرت مورد استفاده قرار می‌گیرد. این نمودار امکان مقایسه پراکندگی متغیرهای مختلف را نیز فراهم می‌کند.



تحلیل ماتریسی و کاهش ابعاد

هدف این بخش

در این مرحله، تمرکز بر ساختار خطی داده‌ها است. ابتدا ماتریس کوواریانس متغیرهای تبلیغاتی محاسبه می‌شود تا میزان هم‌تغییری میان رسانه‌ها مشخص شود. سپس با استفاده از مقادیر ویژه و بردارهای ویژه، و در ادامه تجزیه مقدار منفرد (SVD)، ساختار اصلی داده و سهم هر مؤلفه از واریانس کل بررسی می‌شود.

نرمال‌سازی داده‌ها و محاسبه ماتریس کوواریانس

از آنجا که متغیرهای تبلیغاتی دارای مقیاس‌های متفاوت هستند، ابتدا داده‌ها استانداردسازی می‌شوند. سپس ماتریس کوواریانس محاسبه می‌شود تا الگوی وابستگی خطی بین متغیرهای TV، Radio و Newspaper مشخص شود.

```
[24]: X = data[['TV', 'Radio', 'Newspaper']].values

# نرمال‌سازی
X_mean = np.mean(X, axis=0)
X_std = np.std(X, axis=0)
X_scaled = (X - X_mean) / X_std

# محاسبه ماتریس کوواریانس
# فرمول: C = (X^T * X) / (n-1)
n = X_scaled.shape[0]
cov_matrix = np.dot(X_scaled.T, X_scaled) / (n - 1)

print("Covariance Matrix:\n", cov_matrix)

Covariance Matrix:
[[1.00502513 0.05508408 0.05693254]
 [0.05508408 1.00502513 0.35588317]
 [0.05693254 0.35588317 1.00502513]]
```

مقادیر ویژه، بردارهای ویژه و SVD

در این بخش، داده‌های استانداردشده با استفاده از تجزیه SVD به سه ماتریس اصلی تجزیه می‌شوند. مقادیر منفرد و مقادیر ویژه نشان می‌دهند که چه مقدار از ساختار داده در هر مؤلفه نهفته است. نسبت واریانس توضیح داده‌شده نیز مشخص می‌کند که هر جزء اصلی چه سهمی از اطلاعات کل داده را توضیح می‌دهد.

```
[25]: # اجرای SVD
      U, S, Vt = np.linalg.svd(X_scaled)

      eigenvalues = (S**2) / (n - 1)
      explained_variance_ratio = eigenvalues / np.sum(eigenvalues)

      print(f"Explained Variance Ratio: {explained_variance_ratio}")

Explained Variance Ratio: [0.45695084 0.32775205 0.21529712]

[27]: X_reg = np.column_stack([np.ones(X.shape[0]), X])
      y_reg = data['Sales'].values

      beta = np.linalg.pinv(X_reg).dot(y_reg)

      print(f"Coefficients (Intercept, TV, Radio, Newspaper): {beta}")

Coefficients (Intercept, TV, Radio, Newspaper): [ 2.93888937e+00  4.57646455e-02  1.88530017e-01 -1.03749304e-03]
```

مدل سازی رگرسیون خطی

هدف این بخش

در این مرحله، هدف پیش‌بینی Sales بر اساس هزینه‌های تبلیغاتی در سه رسانه است. برای این منظور، مدل رگرسیون خطی با روش حداقل مربعات برازش داده می‌شود. ضرایب مدل از طریق حل دستگاه معادلات خطی و استفاده از شبه‌معکوس ماتریس محاسبه می‌شوند. سپس برای بررسی معناداری ضرایب، آزمون t و مقادیر p-value استخراج می‌گردند.

تشکیل ماتریس طراحی و برآورد ضرایب

در این قسمت، یک ستون از عدد ۱ به ماتریس ورودی افزوده می‌شود تا عرض از مبدأ مدل نیز برآورد شود. سپس با استفاده از شبه‌معکوس مور-پنروز، بردار ضرایب مدل محاسبه می‌گردد.

محاسبه آماره‌های آزمون و p-value

در این بخش، با محاسبه باقیمانده‌ها و واریانس خطا، خطای استاندارد ضرایب استخراج می‌شود. سپس برای هر ضریب، آماره t و p-value محاسبه می‌گردد تا مشخص شود کدام متغیرها اثر معناداری بر فروش دارند.

```
[32]: from scipy import stats

# ۱. محاسبه پیش‌بینی‌ها و خطا
predictions = X_reg.dot(beta)
residuals = y_reg - predictions

# ۲. واریانس خطاها
RSS = np.sum(residuals**2)
df_resid = X_reg.shape[0] - X_reg.shape[1]
sigma_squared = RSS / df_resid

# ۳. ماتریس واریانس-کوواریانس ضرایب
var_beta = sigma_squared * np.linalg.inv(X_reg.T.dot(X_reg))
se_beta = np.sqrt(np.diag(var_beta))

# ۴. محاسبه t-statistic و p-value
t_stats = beta / se_beta
p_values = [2 * (1 - stats.t.cdf(np.abs(t), df_resid)) for t in t_stats]

print(f"T-stats: {t_stats}")
print(f"P-values: {p_values}")

T-stats: [ 9.42228844 32.80862443 21.89349606 -0.17671459]
P-values: [0.0, 0.0, 0.0, 0.8599150500805934]
```

استدلال بیزی برای احتمال فروش بالا

هدف این بخش

در این مرحله، فروش بالا به عنوان فروش‌هایی تعریف می‌شود که مقدار آن‌ها از میانه فروش بیشتر باشد. سپس با استفاده از یک توزیع پیشین بتا با پارامترهای $(\text{Beta}(1,1))$ ، باور اولیه نسبت به احتمال رخداد فروش بالا تعریف می‌شود. با مشاهده داده‌ها، این توزیع به‌روزرسانی شده و میانگین پسین احتمال فروش بالا برآورد می‌شود.

تعریف فروش بالا و به‌روزرسانی توزیع بتا

در این بخش، ابتدا تعداد نمونه‌هایی که در دسته «فروش بالا» قرار می‌گیرند محاسبه می‌شود. سپس این اطلاعات برای به‌روزرسانی توزیع پیشین بتا استفاده می‌شود. نتیجه نهایی، میانگین پسین احتمال فروش بالا است که یک برآورد بیزی از احتمال رخداد این رویداد محسوب می‌شود.

خروجی این بخش

محل درج خروجی:

مقادیر میانه فروش، تعداد فروش‌های بالا، پارامترهای پسین و میانگین پسین را در اینجا paste کنید.

```
[33]: # ۱. مشخص کردن موفقیت‌ها (Successes)
median_sales = data['Sales'].median()
high_sales_mask = data['Sales'] > median_sales
n_high_sales = np.sum(high_sales_mask)
n_total = len(data)

# ۲. پارامترهای پیشین
alpha_prior = 1
beta_prior = 1

# ۳. به‌روزرسانی بیزی (Posterior)
# در توزیع بتا، پسین به سادگی با جمع زدن تعداد موفقیت‌ها و شکست‌ها به دست می‌آید
alpha_post = alpha_prior + n_high_sales
beta_post = beta_prior + (n_total - n_high_sales)


# ۴. برآورد میانگین پسین
expected_theta = alpha_post / (alpha_post + beta_post)

print(f"Total High Sales: {n_high_sales} out of {n_total}")
print(f"Posterior Mean (Probability of High Sales): {expected_theta:.4f}")
```

```
Total High Sales: 98 out of 200
Posterior Mean (Probability of High Sales): 0.4901
```

رسم توزیع پیشین و پسین

این نمودار تفاوت میان باور اولیه و باور به‌روزشده پس از مشاهده داده‌ها را نشان می‌دهد. توزیع پسین معمولاً متمرکزتر از توزیع پیشین است و عدم قطعیت را کاهش می‌دهد.



5. جمع‌بندی نهایی

نتایج این پروژه نشان داد که داده‌های تبلیغاتی دارای ساختاری مناسب برای تحلیل آماری و مدل‌سازی هستند. تحلیل توصیفی، اطلاعات اولیه‌ای از توزیع و پراکندگی متغیرها فراهم کرد. تحلیل ماتریسی و SVD نشان داد که می‌توان ساختار اصلی داده‌ها را با تعداد کمتری مؤلفه توضیح داد. مدل رگرسیون خطی نیز امکان بررسی کمی اثر هر رسانه بر فروش را فراهم ساخت و آزمون‌های آماری مشخص کردند که کدام ضرایب از نظر آماری معنادار هستند. در نهایت، استدلال بیزی روشی احتمالاتی و قابل تفسیر برای برآورد احتمال رخداد فروش بالا ارائه داد.

به طور کلی، این پروژه نمونه‌ای کامل از ترکیب آمار توصیفی، جبر خطی، رگرسیون کلاسیک و استنباط بیزی در یک مسئله واقعی علم داده است.